

Estimación de probabilidades para conjuntos ordenados y aplicación a la calibración de modelos de calificación.

Leslie G. García Garibay 202066984 Joan M. García Garibay 202066983
Lucy J. Quero Pablo 202052199 José Muñoz Casares 202071990

Mayo 2025

Resumen

El objetivo de este documento es presentar una metodología para estimar las probabilidades de conjuntos ordenados. Esto puede tener varias aplicaciones prácticas, como la calibración de los modelos de calificación, la estimación de las tablas de mortalidad o la medición de los efectos secundarios relacionados con diferentes tamaños de dosis. Para hacer esto, se aplica un enfoque bayesiano objetivo / no informativo, a través del cual, utilizando una prior de Jeffreys anterior multidimensional, se puede inferir una distribución posterior para cada una de las probabilidades que se están estimando.

Palabras clave: Estimación bayesiana, estimación de probabilidad, previa no informativa, calibración de rating / calificación, incumplimiento bajo (low default), conjuntos ordenados, previa de Jeffreys.

1. Introducción

Las calibraciones de ratings crediticios pueden ser problemáticas en portafolios con pocos defaults. En estos casos, es común tener, para varias observaciones de exposiciones crediticias de un año, divididas en diferentes ratings crediticios, un registro binario de su comportamiento crediticio (Default o No Default). Aunque se desea que para ratings crediticios peores se observen mayores Probabilidades de Default (PD), puede darse el caso que, dada la potencial falta de información histórica suficiente, esto no necesariamente ocurra. Para trabajar con un ejemplo particular, se presentan los siguientes datos históricos hipotéticos:

Rating	AAA	AA	A	BBB	BB	B	CCC	CC	C
Exposures	100	100	100	100	100	100	100	100	100
Defaults	1	0	0	1	2	1	2	3	4

Tabla 1: Datos históricos de default hipotéticos

En este caso, por ejemplo, la estimación naive de la PD de AAA (1 %) es mayor que la estimación naive de la PD de AA o A (0 %). Además, la estimación naive de la PD de BB (2 %) es mayor que la estimación naive de la PD de B (1 %). Ninguna de estas situaciones debería ser tolerada en estimaciones de PD s para diferentes ratings crediticios. Esto se debe a que estos ratings se asignan a prestatarios teniendo en cuenta análisis económicos y financieros que deberían tener cierta correlación positiva con sus PD s.

En general, la solución a este problema es ajustar una curva monótonamente creciente a los puntos de datos de PD s. Sin embargo, este enfoque no es objetivo porque la forma funcional de la curva se elige, en general, mediante un análisis subjetivo. Esta subjetividad puede plantear problemas importantes para el uso práctico de estas estimaciones, dado que un cambio en las elecciones subjetivas puede generar cambios importantes en las inferencias económicas que pueden hacerse con estas PD s.

Para resolver este problema, se presenta un enfoque Bayesiano Objetivo/No Informativo. Usando una Simulación de Montecarlo, se proponen diferentes curvas ordenadas de PD s y cada una de ellas se pondera con una medida de consistencia con los defaults observados. Dado que:

- Las curvas de PD s propuestas están ordenadas (respetando la jerarquía de ratings).
- Se usan los mismos pesos entre las diferentes estimaciones de PD de cada nivel.

Las probabilidades estimadas resultantes están ordenadas de forma adecuada y natural. Además, este orden se logra a través de un procedimiento objetivo, dado que el método utilizado para generar los escenarios de curvas de PD s se basa en una distribución previa Objetiva / No informativa.

Este documento está organizado de la siguiente manera:

- **Resumen de Métodos Bayesianos:** Se presenta una recapitulación de los Métodos Bayesianos usualmente utilizados para estimaciones de parámetros y una descripción de las principales distribuciones previas Objetivas/No Informativas utilizadas para este objetivo (Prior de Jeffreys y Prior de Referencia).

-
- **Derivación de la Distribución Previa:** Para este problema particular de Calibración de Ratings, utilizando los métodos presentados en el capítulo anterior, se deriva una Distribución Conjunta Previa de Jeffreys.
 - **Simulación de Escenarios:** Considerando la Distribución Conjunta Previa de Jeffreys derivada en el capítulo anterior, se construye e implementa un Modelo de Montecarlo para simular curvas ordenadas de PD s y, como consecuencia, se analizan sus principales resultados.
 - **Estimación de PD s:** Con las curvas ordenadas de PD s simuladas en el capítulo anterior, se estima la PD de cada nivel de rating. Como consecuencia, para diferentes variaciones de las bases de datos históricas hipotéticas, se analizan y sensibilizan estas estimaciones.

2. Resumen de Métodos Bayesianos

Para presentar los principales Métodos Bayesianos, la exposición se limitará al problema de estimar probabilidades. Sin embargo, es importante considerar que estos métodos se aplican naturalmente a muchos otros problemas de estimación, como estimaciones de medias, desviaciones estándar o modelos de regresión.

En el caso de la estimación de una probabilidad, su estimación naïve se logra midiendo la frecuencia relativa de ocurrencia de un evento, observado en un número de repeticiones del experimento. En casos de estimaciones de PD s para portafolios con pocos defaults, puede suceder que no haya ocurrencias de default y, como consecuencia, la estimación naïve de la PD correspondiente sería 0. Sin embargo, al usar esta estimación para medir Provisiones de Riesgo Crediticio o Requerimientos de Capital Económico, esto produciría resultados no positivos, lo cual no suena prudente.

Como consecuencia, una medición Bayesiana puede ser útil en esta situación. En este caso, para diferentes escenarios de PD , se puede medir qué tan consistente es cada escenario con respecto a los datos observados. Suponiendo " n " observaciones y " x " defaults, esta medición de consistencia puede calcularse mediante la Probabilidad Binomial de observar " x " éxitos en " n " experimentos con una probabilidad de éxito de " PD ":

$$Bin(n, x, PD) = \binom{n}{x} PD^x (1 - PD)^{n-x} \quad (1)$$

Y, como consecuencia, la estimación de la PD para este escenario (llamémosla $\overline{PD}$) de " x " defaults en " n " exposiciones históricas, puede calcularse promediando cada escenario de PD usando un peso proporcional a la medición de consistencia binomial:

$$\overline{PD} = \frac{\int_0^1 PD \cdot \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot 1 \cdot dPD}{\int_0^1 \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot 1 \cdot dPD} \quad (2)$$

En esta ecuación, se ha escrito explícitamente un segundo peso de 1. Estos dos pesos (el peso binomial y el peso uno, pueden interpretarse de la siguiente manera:

1. **Peso "uno":** Cada escenario es igualmente probable. La naturaleza generaría escenarios de PD de manera uniforme.

-
2. **Peso "Binomial"**: una vez generado el escenario de PD , cuanto más probable sea observar los datos de default, mayor debería ser el peso de ese escenario.

En una interpretación informal, esto puede verse como si el universo se ramificara en la combinación infinita de escenarios de PD s y número de defaults ("x"). En estos términos, intuitivamente, para cada valor de PD , el producto de estos dos pesos es proporcional a la cantidad de escenarios consistentes con ese valor de PD y con la cantidad de defaults "x" observados.

El peso uno se considera generalmente como la Distribución Previa del parámetro. Además, después de multiplicar los dos pesos y dividirlos por la suma de los productos de ambos pesos para cada uno de los escenarios de PD , se obtiene una nueva distribución. Esta nueva distribución suele llamarse Distribución Posterior del parámetro (en este caso, la Distribución Posterior de la PD).

Se puede demostrar que la Ecuación 2 produce un resultado de $(x + 1)/(n + 2)$. Este resultado, para n grande, está más cerca de la estimación naive de la PD para " $x + 1$ " éxitos que de la estimación naive de la PD para " x " éxitos. Como consecuencia, parece que esta fórmula debería tener algún tipo de ajuste. De hecho, se puede demostrar que este ajuste debería hacerse a lo que se ha llamado el peso "*uno*".

El peso "*uno*", dado que representa un peso uniforme, puede parecer una elección objetiva. Sin embargo, puede demostrarse que no es necesariamente objetivo. Hay dos observaciones que pueden hacerse sobre esta elección: su falta de invarianza después de un cambio en la parametrización del problema y su no minimización de la información añadida al problema.

1. Falta de invarianza después de un cambio en la parametrización del problema:

En este contexto, estamos trabajando con un problema binomial representado por la Ecuación 1. Dado que este problema generalmente se plantea en términos de la probabilidad de éxito (" PD "), es habitual suponer que esta PD debería ser uniforme. Sin embargo, nada impide el uso de otra parametrización de la distribución binomial. Por ejemplo, definiendo una nueva variable θ , que varía entre 0 y $\pi/2$, si aplicamos la siguiente transformación de coseno cuadrado:

$$PD = \cos(\theta)^2 \quad (3)$$

podemos expresar la distribución binomial de la siguiente manera:

$$Bin(n, x, \theta) = \binom{n}{x} \cos(\theta)^{2x} \sin(\theta)^{2n-2x} \quad (4)$$

Si la práctica general fuera plantear el problema binomial mediante la Ecuación 4, estaríamos tentados a asignar una distribución uniforme al parámetro θ . Sin embargo, en este caso, si transformamos el problema de vuelta a la forma de la Ecuación 1 (usando la transformación de la Ecuación 3), el parámetro PD heredaría (del parámetro θ) una distribución no uniforme. Como consecuencia, dependiendo de la parametrización en que se exprese el problema, la distribución previa puede diferir. Por lo tanto, los resultados de estimación dependerán de la selección subjetiva de

la parametrización del problema.

Para evitar este problema, existe una metodología llamada "prior de Jeffreys" (Jeffreys 1946, 1961), que establece que una Distribución Previa invariante, para una distribución general $p(x|\gamma)$ (no necesariamente binomial), con una variable aleatoria vectorial m -dimensional x y un parámetro vectorial n -dimensional γ , puede calcularse como sigue:

$$\pi(\gamma_1, \gamma_2, \dots, \gamma_n) = \sqrt{\det(I(\gamma))} \quad (5)$$

Donde $I(\gamma)$ representa la Matriz de Información con elemento (i, j) :

$$I(\gamma)_{i,j} = E_{x|\gamma} \left[\frac{\partial \log(p(x|\gamma))}{\partial \gamma_i} \frac{\partial \log(p(x|\gamma))}{\partial \gamma_j} \right] \quad (6)$$

En particular, aplicando esta metodología al problema binomial (unidimensional), donde $\gamma = PD$ y $p(x|\gamma)$ es igual a $\binom{n}{x} PD^x (1 - PD)^{n-x}$, obtenemos:

$$\frac{\partial \log(Bin(n, x, PD))}{\partial PD} = \frac{x}{PD} - \frac{n - x}{1 - PD} \quad (7)$$

Por lo tanto, su matriz de información es solo un escalar dado por el valor esperado del cuadrado de la ecuación 7, que a su vez es igual a:

$$\begin{aligned} I(PD) &= E_{x|PD} \left[\left(\frac{x}{PD} - \frac{n - x}{1 - PD} \right)^2 \right] \\ &= E_{x|PD} \left[\left(\frac{x}{PD} \right)^2 \right] - E_{x|PD} \left[2 \frac{x}{PD} \frac{n - x}{1 - PD} \right] + E_{x|PD} \left[\left(\frac{n - x}{1 - PD} \right)^2 \right] \end{aligned}$$

Considerando que:

$$\begin{aligned} E_{x|PD} \left[\left(\frac{x}{PD} \right)^2 \right] &= \frac{n \cdot PD \cdot (1 - PD) + n^2 \cdot PD^2}{PD^2} \\ E_{x|PD} \left[\left(\frac{n - x}{1 - PD} \right)^2 \right] &= \frac{n \cdot PD \cdot (1 - PD) + n^2 \cdot (1 - PD)^2}{(1 - PD)^2} \\ -E_{x|PD} \left[2 \frac{x}{PD} \frac{n - x}{1 - PD} \right] &= -2E_{x|PD} \left[\frac{n \cdot x}{PD \cdot (1 - PD)} \right] + 2E_{x|PD} \left[\frac{x^2}{PD \cdot (1 - PD)} \right] \\ &= -2 \frac{n^2}{(1 - PD)} + 2 \frac{n \cdot PD \cdot (1 - PD + n^2 \cdot PD^2)}{PD \cdot (1 - PD)} = +2n - 2n^2 \end{aligned}$$

Sumando los tres términos, la matriz de información es igual a:

$$I(PD) = \frac{n}{PD \cdot (1 - PD)}$$

Dado que esta matriz es unidimensional, el cálculo de su determinante es trivial y, por lo tanto, el Prior de Jeffreys, dado por la Ecuación 5, es igual a:

$$\pi(PD) = \frac{1}{\sqrt{PD \cdot (1 - PD)}} \quad (8)$$

En esta expresión hemos eliminado la constante $\sqrt{n}$ en el numerador dado que no contribuye de ninguna manera en la ponderación de los escenarios de PD .

Con esta distribución previa, la estimación Bayesiana de PD es:

$$PD = \frac{\int_0^1 PD \cdot \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD) \cdot dPD}{\int_0^1 \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD) \cdot dPD} \quad (9)$$

La Ecuación 9 puede resolverse analíticamente y puede demostrarse que el resultado de esta estimación es el siguiente:

$$PD = \frac{x + 0.5}{n + 1} \quad (10)$$

Esta fórmula tiene muchas ventajas en comparación con la estimación tradicional de probabilidades y con la estimación Bayesiana de probabilidades basada en un Prior Uniforme:

- (a) Representa un valor intermedio entre la estimación naïve de la PD para " $x + 1$ " éxitos y la estimación naïve de la PD para " x " éxitos. Como consecuencia, este resultado, calculado usando el Prior de Jeffreys, parece más razonable que el resultado obtenido usando un Prior Uniforme.
- (b) También vale la pena destacar que, cuando $x = 0$, esta estimación Bayesiana de la PD es igual a $0.5/(n + 1)$. Por lo tanto, este método proporciona un procedimiento objetivo para generar una estimación no cero de la PD para datos históricos con cero defaults.

Por último, es importante mencionar que, si hubiéramos calculado el Prior de Jeffreys para la Distribución Binomial, usando la parametrización descrita por la Ecuación 4, habríamos obtenido que la Distribución de Jeffreys invariante para θ es igual a la Distribución Uniforme.

2. No minimización de la información añadida al problema:

Dado lo descrito hasta este punto, está claro que la Distribución Uniforme no representa una Elección Objetiva (teniendo en cuenta que la Uniformidad de la PD depende de la decisión subjetiva relacionada con la parametrización de la Distribución Binomial). Además de esto, puede afirmarse que la Distribución Uniforme no minimiza la información (subjetiva) añadida al problema.

Siguiendo una metodología iniciada en Bernardo (1979), el problema de encontrar la distribución previa estadística que minimiza la información (subjetiva) añadida al problema de inferencia puede formularse matemáticamente. Su enfoque se basa en encontrar lo que se llama el Prior de Referencia. Es decir, la Distribución Previa que maximiza la Información Mutua entre los datos observados (x en términos

generales) y los Parámetros (γ en términos generales. Teniendo en cuenta que la Información Mutua (MI) de dos variables aleatorias (X e Y) con densidad conjunta $f(x, y)$ y densidades marginales $g(x)$ y $h(y)$ puede calcularse como sigue:

$$MI(X, Y) = \iint f(x, y) \cdot \log \frac{f(x, y)}{g(x) \cdot h(y)} \cdot dx dy$$

La Información Mutua de los datos x y los parámetros γ puede calcularse como:

$$MI(x, \gamma) = \iint f(x, \gamma) \cdot \log \frac{f(x, \gamma)}{g(x) \cdot h(\gamma)} \cdot dx d\gamma$$

En particular, para el caso unidimensional de la estimación de PD usando la distribución binomial, este cálculo se reduce a:

$$MI(x, PD) = \sum_{x=0}^n \int_0^1 \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD) \cdot \log \left(\frac{\binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD)}{\int_0^1 \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD) dPD \cdot \pi(PD)} \right) dPD \quad (11)$$

En este caso particular:

- Los datos (x) han sido reemplazados por la cantidad de defaults x
- Los parámetros (γ) fueron reemplazados por la probabilidad de default PD
- La densidad conjunta de los datos y el parámetro ($f(x, \gamma)$) ha sido reemplazada por $\binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD)$
- La densidad de los parámetros $h(\gamma)$ ha sido reemplazada por $\pi(PD)$
- La densidad marginal de los parámetros $g(x)$ ha sido reemplazada por $\int_0^1 \binom{n}{x} PD^x (1 - PD)^{n-x} \cdot \pi(PD) dPD$.

El problema de optimización para encontrar la distribución de los parámetros ($h(\gamma)$) que maximiza la Información Mutua mencionada anteriormente puede ser computacionalmente difícil. Sin embargo, puede demostrarse que, para el problema Binomial establecido en la Ecuación 11, la Distribución Previa de la PD ($\pi(PD)$) que alcanza su máximo coincide con el Prior de Jeffreys (Ecuación 8).

Aunque el método del Prior de Referencia puede ser más preciso para detectar la Distribución Previa que minimiza la subjetividad que el método de Jeffreys (dado que el método de Jeffreys se basa en argumentos de invarianza y no en la minimización de la subjetividad), en lo que sigue, dada su simplicidad computacional, derivaremos nuestras estimaciones usando el Método de Jeffreys.

3. Derivación de la Distribución Previa

Para el problema de calibrar un modelo de rating con " m " niveles de rating, tendríamos para cada nivel " i " una cantidad " n_i " de exposiciones independientes y una cantidad

" x_i " de defaults. Tanto las exposiciones como los defaults pueden agregarse, respectivamente, en vectores " m " dimensionales " n " y " x ". Por lo tanto, la probabilidad de observar el vector de defaults " x " dado el vector de exposiciones " n " y el vector de Probabilidades de Default " PD " es:

$$Bin(n, x, PD) = \prod_{i=1}^m \binom{n_i}{x_i} PD_i^{x_i} (1 - PD_i)^{n_i - x_i} \quad (12)$$

Aplicando la Ecuación 6 a esta ecuación, para obtener la matriz de información, significaría realizar el siguiente cálculo para cada i y j :

$$I(PD)_{i,j} = E_{x_i, x_j | PD_i, PD_j} \left[\left(\frac{x_i}{PD_i} - \frac{n_i - x_i}{1 - PD_i} \right) \left(\frac{x_j}{PD_j} - \frac{n_j - x_j}{1 - PD_j} \right) \right] \quad (13)$$

Para $i \neq j$, dada la independencia de x_i y x_j , este valor esperado puede calcularse aplicando el operador de esperanza a cada uno de los productos. Dado que el valor esperado de ambos productos es 0, la Ecuación 13 es 0 para $i \neq j$.

Para $i = j$, volvemos al caso unidimensional. Como consecuencia, obtenemos que:

$$I(PD)_{i,i} = \frac{n_i}{PD_i \cdot (1 - PD_i)} \quad (14)$$

Por lo tanto, la matriz de información es cero fuera de la diagonal principal e igual a la Ecuación 14 en la diagonal principal. Como consecuencia, su determinante es igual al producto de todos sus elementos diagonales y el Prior de Jeffreys sería igual a la raíz cuadrada de ese producto:

$$\pi(PD) = \prod_{i=1}^m \sqrt{\frac{1}{PD_i \cdot (1 - PD_i)}} \quad (15)$$

Aplicando la transformación de coseno cuadrado establecida en la Ecuación 3 a cada PD_i , como en el caso unidimensional, obtenemos una distribución conjunta uniforme. Es decir, hasta una constante de normalización:

$$\pi(\theta) = 1 \quad (16)$$

4. Simulación de Escenarios

Dada la Ecuación 16, parece más fácil simular escenarios relacionados con θ que con PD . Sin embargo, es importante tener en cuenta que cada par de PD s consecutivas (PD_i y PD_{i+1}) debe respetar la siguiente relación:

$$PD_i < PD_{i+1} \quad (17)$$

O, en términos de θ (dada la relación monótonamente inversa entre PD y θ definida en la Ecuación 3):

$$\theta_i > \theta_{i+1} \quad (18)$$

Considerando la restricción descrita en la Ecuación 18, el Método de Simulación Montecarlo propuesto:

- Comienza simulando un escenario para θ_1 ,
- Luego genera un escenario para θ_2 , restringido a la condición de que θ_2 debe ser menor que θ_1 ,
- A continuación genera un escenario para θ_3 , restringido a la condición de que θ_3 debe ser menor que θ_2 ,
- Y este procedimiento continúa operando recursivamente hasta alcanzar la simulación de la última variable (θ_m)

Dado este procedimiento, necesitaremos conocer las siguientes distribuciones:

- Distribución marginal de θ_1
- Distribución de θ_2 condicionada a la ocurrencia de θ_1
- Distribución de θ_3 condicionada a la ocurrencia de θ_2
- ...
- Distribución de θ_m condicionada a la ocurrencia de θ_{m-1}

En lugar de derivar estas distribuciones mediante procedimientos analíticos, analizaremos visualmente sus densidades para los casos $m = 2$ y $m = 3$ y, considerando su simple distribución conjunta dada en la Ecuación 16, extrapolaremos fácilmente nuestras conclusiones al caso general m -dimensional. Además, para simplificar este cálculo, trabajaremos con variables restringidas al intervalo $[0, 1]$ y luego ajustaremos la simulación para representar el intervalo correcto $([0, \frac{\pi}{2}])$.

Para el caso $m = 2$, la región admisible de θ es el conjunto de pares (θ_1, θ_2) tales que $\theta_1 > \theta_2$. Esta región puede representarse mediante el siguiente gráfico:




Figura 1: Región Admisible

Dado que cada punto de la Región Admisible tiene la misma probabilidad (debido a la uniformidad de la Distribución Previa de θ), existen más escenarios admisibles para valores altos de θ_1 que para valores bajos. A medida que nos movemos de izquierda a

derecha en el gráfico, la cantidad de escenarios admisibles crece linealmente. Por lo tanto, podemos ver fácilmente que la Distribución Acumulada de θ_1 ($CD(\theta_1)$) es igual al área del triángulo acumulada desde el valor cero en el eje x hasta el valor θ_1 (esta área es igual a $\frac{\theta_1^2}{2}$) dividida por el área total de la región admisible (que es igual a $1/2$):

$$CD(\theta_1) = \theta_1^2$$

Una vez obtenida una simulación de θ_1 , sabemos que:

- La simulación de θ_2 debe ser menor que el valor simulado de θ_1 .
- Dada la Ecuación 16, cada escenario es igualmente probable.

Como consecuencia, la Distribución Acumulada condicionada de θ_2 es:

$$CD(\theta_2|\theta_1) = \frac{\theta_2}{\theta_1}$$

Para el caso $m = 3$, podemos generalizar lo obtenido del caso $m = 2$. La región admisible sería un volumen tridimensional. Para el caso particular de $\theta_3 = 0$, la región admisible (θ_1, θ_2) sería la misma que la representada anteriormente. Para un valor genérico positivo de θ_3 , la región admisible (θ_1, θ_2) correspondiente sería también un triángulo rectángulo similar pero cuyo vértice inferior izquierdo es (θ_3, θ_3) y cuyo vértice superior derecho es $(1, 1)$. Como consecuencia, podemos representar la región admisible tridimensional de la siguiente manera:




Figura 2: Región Admisible: 3-Dimensional

Al moverse de izquierda a derecha en la dirección x (es decir, en la dirección θ_1), aumenta la región admisible (θ_2, θ_3) . Para cada valor θ_1 , la región admisible bidimensional correspondiente (θ_2, θ_3) tiene un área de $\frac{\theta_1^2}{2}$. Como consecuencia, la densidad de θ_1 debe ser proporcional a esta área y la integral de esta área debe ser proporcional a la Función de Distribución Acumulada Marginal de θ_1 . Dado que la integral de $\frac{\theta_1^2}{2}$ es proporcional a θ_1^3 y que θ_1^3 es igual a 1 cuando θ_1 es igual a 1, podemos concluir que:

$$CD(\theta_1) = \theta_1^3$$

Habiendo determinado un escenario particular para θ_1 , volvemos al problema bidimensional, con la única diferencia de que nuestra región admisible (θ_2, θ_3) debe estar restringida a $\theta_2 < \theta_1$ y $\theta_3 < \theta_1$. Como consecuencia, el área del triángulo total es $\frac{\theta_1^2}{2}$. Escalando apropiadamente lo mencionado para el caso $m = 2$, podemos concluir que:

$$CD(\theta_2|\theta_1) = \left(\frac{\theta_2}{\theta_1}\right)^2$$

$$CD(\theta_3|\theta_2) = \frac{\theta_3}{\theta_2}$$

Extrapolando estas ideas al caso m -dimensional, podemos obtener las siguientes distribuciones acumuladas marginales y condicionales:

$$CD(\theta_1) = \theta_1^m \tag{19}$$

$$CD(\theta_{i+1}|\theta_i) = \left(\frac{\theta_{i+1}}{\theta_i}\right)^{m-i}$$

Para realizar simulaciones Montecarlo, es común trabajar con las inversas de las Distribuciones Acumuladas. Considerando las Ecuaciones 19, estas son directas:

$$\theta_1 = CD(\theta_1)^{1/m}$$

$$\theta_{i+1} = CD(\theta_{i+1}|\theta_i)^{1/(m-i)}\theta_i \tag{20}$$

Como consecuencia, el Proceso de Simulación Montecarlo será el siguiente:

1. Generar m números aleatorios uniformes independientes en el intervalo $[0, 1]$.
2. Sustituirlos en las variables $CD(\theta_1)$ y $CD(\theta_{i+1}|\theta_i)$ de las Ecuaciones 26 y 27 para obtener el vector simulado $\boldsymbol{\theta}$.
3. Dado que estos parámetros están restringidos al intervalo $[0, 1]$, y necesitamos variables en el intervalo $[0, \frac{\pi}{2}]$, multiplicamos el vector simulado $\boldsymbol{\theta}$ por $\frac{\pi}{2}$.
4. Calcular el vector $\mathbf{PD}$ aplicando la transformación de coseno cuadrado establecida en la Ecuación 3 a cada elemento del vector simulado $\boldsymbol{\theta}$.

Para analizar los resultados simulados, a continuación se presenta una distribución marginal simulada para cada PD en un problema 9-dimensional:

Distribuciones marginales de PDs simuladas




Figura 3: PDs distribucion Marginal: Problema 9-Dimensional

Como puede observarse, PD_5 es una distribución simétrica. El resto de las distribuciones están relacionadas en pares. La distribución de PD_1 es una transformación especular de la distribución de PD_9 . Lo mismo ocurre entre PD_2 y PD_8 , PD_3 y PD_7 , y PD_4 y PD_6 . Estas propiedades de simetría son deseables, dada la uniformidad de la densidad conjunta presentada en la Ecuación 16.

5. Estimación de PDs

El último paso del procedimiento es realizar la estimación Bayesiana de PD . Analíticamente, para una calibración de m dimensiones, la estimación de cada PD_i debería realizarse mediante:

$$\overline{PD}_i = \frac{N_i}{D} \quad (21)$$

$$\text{Con } \pi(PD) = \prod_{i=1}^m \sqrt{\frac{1}{PD_i(1-PD_i)}}.$$

donde:

$$N_i = \int \cdots \int_{\substack{0 < PD_m < \cdots \\ < PD_1 < 1}} PD_i \cdot \prod_{i=1}^m \binom{n_i}{x_i} PD_i^{x_i} (1 - PD_i)^{n_i - x_i} \cdot \pi(\mathbf{PD}) d\mathbf{PD}$$

$$D = \int \cdots \int_{\substack{0 < PD_m < \cdots \\ < PD_1 < 1}} \prod_{i=1}^m \binom{n_i}{x_i} PD_i^{x_i} (1 - PD_i)^{n_i - x_i} \cdot \pi(\mathbf{PD}) d\mathbf{PD}$$

Esta es una integral m -dimensional que no puede resolverse analíticamente de forma sencilla. Sin embargo, puede aproximarse mediante el procedimiento de simulación descrito anteriormente. Esta aproximación funciona como se muestra:

$$\overline{PD}_i = \frac{\sum_{\omega \in \Omega} PD(\omega)_i \cdot L(\omega)}{\sum_{\omega \in \Omega} L(\omega)} \quad (22)$$

donde:

$$L(\omega) = \prod_{i=1}^m \binom{n_i}{x_i} \mathbf{PD}(\omega)_i^{x_i} (1 - \mathbf{PD}(\omega)_i)^{n_i - x_i}$$

Ω = conjunto de todos los escenarios simulados

ω = un escenario simulado particular

$\mathbf{PD}(\omega)_i$ = valor de PD simulado para el rating i en el escenario ω

En la Ecuación 22, Ω representa el conjunto de todos los escenarios simulados, ω representa un escenario simulado particular y $PD(\omega)_i$ representa la PD simulada para el nivel i -ésimo en el escenario ω .

La implementación de este procedimiento se realizará en un contexto de 9 dimensiones, con los datos mostrados en la Tabla 2. A continuación se presenta una comparación entre Los resultados de implementar la Ecuación 22 usando 1.000.000.000 escenarios de curvas de PD , La estimación naive de cada PD y La estimación Bayesiana unidimensional establecida en la Ecuación 10 para cada PD :

Notch	Naive	1D Bayes	9D Bayes	Montecarlo	# Defaults	# Exposures
AAA	1,00 %	1,49 %		0,20 %	1	100
AA	0,00 %	0,50 %		0,35 %	0	100
A	0,00 %	0,50 %		0,59 %	0	100
BBB	1,00 %	1,49 %		1,00 %	1	100
BB	2,00 %	2,48 %		1,50 %	2	100
B	1,00 %	1,49 %		2,00 %	1	100
CCC	2,00 %	2,48 %		2,77 %	2	100
CC	3,00 %	3,47 %		3,93 %	3	100
C	4,00 %	4,46 %		5,95 %	4	100

Tabla 2: 9D Bayes Montecarlo

En nuestro Código en R:

	Notch <chr>	Naive <dbl>	Bayes1D <dbl>	Bayes9D_Montecarlo <dbl>	Defaults <dbl>	Exposures <dbl>
AAA	AAA	1	1.49	0.19	1	100
AA	AA	0	0.50	0.34	0	100
A	A	0	0.50	0.58	0	100
BBB	BBB	1	1.49	1.00	1	100
BB	BB	2	2.48	1.51	2	100
B	B	1	1.49	2.00	1	100
CCC	CCC	2	2.48	2.77	2	100
CC	CC	3	3.47	4.00	3	100
C	C	4	4.46	5.96	4	100

Tabla 2: 9D Bayes Montecarlo

Los resultados pueden variar ligeramente entre ejecuciones debido a la naturaleza aleatoria.

Como era de esperar, ni la estimación naive ni la estimación Bayesiana 1D producen estimaciones ordenadas. Como también se esperaba, dada su coincidencia teórica, el método Bayesiano 9D Montecarlo presentado en este documento está más cerca de las estimaciones Bayes 1D que de las naïve. La estimación Bayes 9D difiere más de las demás en el nivel C. Esto puede deberse a que, dado el orden impuesto a los escenarios, esta estimación de la PD para el nivel C deja más espacio para que el resto de estimaciones de PD se ajusten adecuadamente al conjunto de datos.

Como análisis final, dada esta diferencia en la estimación de la PD para el nivel C, se cambió la cantidad de defaults solo para este nivel de 4 a 9. Los resultados obtenidos son los siguientes:

Notch	Naive	1D Bayes	9D Bayes Montecarlo	# Defaults	# Exposures
AAA	1,00 %	1,49 %	0,20 %	1	100
AA	0,00 %	0,50 %	0,36 %	0	100
A	0,00 %	0,50 %	0,61 %	0	100
BBB	1,00 %	1,49 %	1,04 %	1	100
BB	2,00 %	2,48 %	1,57 %	2	100
B	1,00 %	1,49 %	2,12 %	1	100
CCC	2,00 %	2,48 %	3,03 %	2	100
CC	3,00 %	3,47 %	4,65 %	3	100
C	9,00 %	9,41 %	9,69 %	9	100

Tabla 3: Notch C cambiado: 9D Bayes Montecarlo.

En nuestro Código en R:

	Notch <chr>	Naive <dbl>	Bayes1D <dbl>	Bayes9D_Montecarlo <dbl>	Defaults <dbl>	Exposures <dbl>
AAA	AAA	1	1.49	0.19	1	100
AA	AA	0	0.50	0.35	0	100
A	A	0	0.50	0.60	0	100
BBB	BBB	1	1.49	1.02	1	100
BB	BB	2	2.48	1.58	2	100
B	B	1	1.49	2.12	1	100
CCC	CCC	2	2.48	3.00	2	100
CC	CC	3	3.47	4.65	3	100
C	C	9	9.41	9.87	9	100

Tabla 3: Notch C cambiado: 9D Bayes Montecarlo

Los resultados pueden variar ligeramente entre ejecuciones debido a la naturaleza aleatoria.

Como puede observarse, dado que existe mayor diferencia entre las tasas de default observadas para los niveles CC y C, la estimación Bayesiana 9D para el nivel C reduce casi completamente su diferencia con la correspondiente estimación Bayesiana 1D. La conclusión sería que, con mayores diferencias entre las tasas de default observadas de los distintos niveles de rating, habría mayor coincidencia entre las estimaciones Bayes 1D y las estimaciones Bayes 9D.

6. Observaciones finales

Los métodos naive para estimar las probabilidades necesitan el uso de una cierta cantidad de subjetividad. Esta subjetividad puede plantear problemas importantes para el uso práctico de estas estimaciones, dado que un cambio en las opciones subjetivas puede generar cambios importantes en las inferencias económicas que se pueden hacer con estas probabilidades. Los métodos bayesianos presentados en este documento ofrecen un procedimiento objetivo para estimar las probabilidades tanto para carteras de bajo incumplimiento (low default portfolios) como para niveles de calificación ordenadas (ordered rating notches).

Hay desafíos numéricos al aplicar esta metodología a algunos contextos particulares. Por ejemplo, cuando hay una gran cantidad de niveles de calificación, la cantidad de escenarios necesarios para alcanzar un nivel razonable de precisión puede ser infactible bajo límites computacionales reales. Como consecuencia, pueden ser necesarios algunos ajustes, teniendo en cuenta las características particulares del problema bajo análisis, para adquirir un nivel suficiente de precisión.

Anexo 1: Algoritmo Python para la estimación 9D Bayes Montecarlo

```
1 " IMPORTAR LIBRARIES "
2 import numpy
3 from numpy import random
4 import math
5
6 " DEFINE DATASETS "
7 X = [1,0,0,1,2,1,2,3,9]
8 N = [100,100,100,100,100,100,100,100,100]
9
10 " INTIALIZE VARIABLES "
11 PDEst = X*0
12 Esc = 10000000000
13 tita = numpy.zeros((Esc,9))+1
14 PRODBIN = numpy.zeros((Esc,1))
15 PDEst = numpy.zeros((9,1))
16 DENEst = numpy.zeros((9,1))
17
18 " SIMULATION MODEL "
19 " IT STARTS FROM LAST NOTCH BECAUSE, FOR NUMERICAL REASONS, IT IS
    NEEDED TO "
20 " LIMIT THE LAST THETA VALUE TO 0,5 AT MOST "
21 for i in range(9):
22     t = 8-i
23     x = random.rand(Esc,1)
24     if t == 8:
25         tita[:,8] = pow(x[:,0],1/(8+1))*0.5
26     else:
27         tita[:,t] = pow(x[:,0],1/(t+1))*tita[:,t+1]
28
29 PD = pow(numpy.cos(math.pi/2-tita*math.pi/2),2)
30 BINOMIAL = PD*0
31
32 " WEIGHT CALCULATION "
33 for i in range(9):
34     t = 8-i
35     BINOMIAL[:,i] = PD[:,i]**X[i]*(1-PD[:,i])** (N[i]-X[i])
36 PRODBIN[:,0] = numpy.prod(BINOMIAL,i)
37
38 " PD ESTIMATION "
39 for i in range(9):
40     PDEst[i] = numpy.sum(PD[:,i]*PRODBIN[:,0])/numpy.sum(PRODBIN[:,0])
```

Como se observa en el código Python, el algoritmo implementado comienza desde el último nivel de rating y no desde el primero. Esto fue necesario porque la simulación de la última variable θ fue truncada para ser, como máximo, 0.5. Aunque esto introduce un sesgo conceptual en las estimaciones, las probabilidades binomiales de los escenarios descartados eran insignificantes. Por lo tanto, su contribución a las estimaciones totales también resultó insignificante. A cambio, si se hubieran mantenido esos escenarios, se habría generado que existieran muy pocos escenarios de la variable θ_9 alrededor del valor observado. Como consecuencia, la estimación del parámetro PD_9 habría tenido un error estadístico mucho mayor.

Anexo 2: Algoritmo en R para la estimación 9D Bayes Montecarlo

```
1 # Funcion 9D Bayes Montecarlo (Estimacion Bayesiana Multidimensional
  Ordenada).
2
3 bayes_9D_PD <- function(defaults, exposures, num_sim = 1000000000) {
4   set.seed(123)
5   m <- length(defaults)
6
7   # Funcion para simular theta ordenado
8   simulate_thetas <- function(n_sim, m) {
9     theta <- matrix(nrow = n_sim, ncol = m)
10    for (i in 1:n_sim) {
11      u <- runif(m)
12      theta[i, m] <- u[m]^(1/m) * 0.5 # theta 9 truncado
13      for (j in (m-1):1) {
14        theta[i, j] <- theta[i, j+1] * u[j]^(1/j)
15      }
16    }
17    return(theta)
18  }
19
20  # Simular thetas y transformar a PDs
21  theta <- simulate_thetas(num_sim, m)
22  PD_sim <- cos(pi/2 - theta * pi/2)^2
23
24  # Calcular pesos binomiales para cada escenario
25  weights <- matrix(1, nrow = num_sim, ncol = m)
26  for (i in 1:m) {
27    weights[, i] <- dbinom(defaults[i], exposures[i], PD_sim[, i])
28  }
29  total_weights <- apply(weights, 1, prod)
30
31  # Estimaci n PD ponderada
32  PD_estimates <- numeric(m)
33  for (i in 1:m) {
34    PD_estimates[i] <- sum(PD_sim[, i] * total_weights) / sum(total_
      weights)
35  }
36
37  names(PD_estimates) <- c("AAA", "AA", "A", "BBB", "BB", "B", "CCC", "
    CC", "C")
38  return(round(PD_estimates * 100, 2))
39 }
```

Anexo 3: Algoritmo en R para la estimación de PDs por Método Naive y 1D Bayes

```
1 # Funcion Naive (Estimacion por Frecuencia Relativa).
2
3 naive_PD <- function(defaults, exposures) {
4   PD <- defaults / exposures
5   names(PD) <- c("AAA", "AA", "A", "BBB", "BB", "B", "CCC", "CC", "C")
6   return(round(PD * 100, 4))
7 }
```

```
1 # Funcion 1D Bayes (Estimacion Bayesiana Unidimensional).
2
3 bayes_1D_PD <- function(defaults, exposures) {
4   PD <- (defaults + 0.5) / (exposures + 1)
5   names(PD) <- c("AAA", "AA", "A", "BBB", "BB", "B", "CCC", "CC", "C")
6   return(round(PD * 100, 2))
7 }
```

Función para Replicar la Tabla 3 de este Paper:

```
1 replicar_tabla3 <- function() {
2   # Datos de la Tabla 3 (C notch cambiado a 9 defaults)
3   defaults <- c(1, 0, 0, 1, 2, 1, 2, 3, 9)
4   exposures <- rep(100, 9)
5
6   # Calcular estimaciones
7   naive <- naive_PD(defaults, exposures)
8   bayes1D <- bayes_1D_PD(defaults, exposures)
9   bayes9D <- bayes_9D_PD(defaults, exposures, num_sim = 10000000)
10
11  # Crear tabla de resultados
12  tabla <- data.frame(
13    Notch = c("AAA", "AA", "A", "BBB", "BB", "B", "CCC", "CC", "C"),
14    Naive = naive,
15    Bayes1D = bayes1D,
16    Bayes9D_Montecarlo = bayes9D,
17    Defaults = defaults,
18    Exposures = exposures
19  )
20
21  return(tabla)
22 }
23
24 # Ejecutar para obtener resultados id nticos a la Tabla 3
25 resultados_tabla3 <- replicar_tabla3()
26 print(resultados_tabla3)
```

Recordemos que: *los resultados pueden variar ligeramente entre ejecuciones debido a la naturaleza aleatoria.*

Referencias

- [1] Basel Committee on Banking Supervision (2004), *Basel II: International Convergence of Capital Measurement and Capital Standards: A Revised Framework section 444 to 485*, Bank for International Settlements.
- [2] Basel Committee on Banking Supervision (2005). *An Explanatory Note on the Basel II IRB Risk Weight Function*, Bank for International Settlements.
- [3] Basel Committee on Banking Supervision (2011), *Basel III: A global regulatory framework for more resilient banks and banking systems.*, Bank for International Settlements.
- [4] Berger, J. O. and Bernardo, J. M. (1992c). *On the development of reference priors (with discussion)*. In *Bayesian Statistics 4*. (J. M. Bernardo, J. O. Berger, A. P. Dawid and A. F. M. Smith, eds.) 35–60. Oxford Univ. Press
- [5] Bernardo, J. M. (1979). *Reference posterior distributions for Bayesian inference (with discussion)*. J. Roy. Statist. Soc. Ser. B 41 113–147. [Reprinted in *Bayesian Inference* (N. G. Polson and G. C. Tiao, eds.) 229–263. Edward Elgar, Brookfield, VT, 1995.]
- [6] Bernardo, J. M. (2005). *Reference analysis*. In *Handbook of Statistics 25* (D. K. Dey and C. R. Rao, eds.) 17–90. North-Holland, Amsterdam.
- [7] IASB (2014): *International Financial Reporting Standard 9 Financial Instruments*. Including Implementation Guidance and Basis for Conclusions (IFRS 9, final standard).
- [8] Jeffreys, H. (1946). *An invariant form for the prior probability in estimation problems*. Proc. Royal Soc. of London, Series A, 186, 453–461.
- [9] Jeffreys, H. (1961). *Theory of Probability, 3rd Edition*, Clarendon Press, Oxford.
- [10] Kullback, S. (1959). *Information Theory and Statistics, 2nd Edition*. Dover, New York.
- [11] Kullback, S. and Leibler, R. A. (1951). *On information and sufficiency*. Ann. Math. Statist. 22 79–86.
- [12] Shannon, C. E. (1948). *A mathematical theory of communication*. Bell System Tech. J. 27 379–423, 623–656.
- [13] Tasche, D., Pluto, K. (2005), *Estimating Probabilities of Default for Low Default Portfolios*, Deutsche Bundesban.