

A7.Modelos binarios

José Muñoz Casares Leslie Guadalupe García Garibay
Joan Manuel García Garibay Lucy Janell Quero Pablo

Domingo, 25 de Mayo de 2025.

Contents

1	Introducción	2
1.1	Contexto y Relevancia	2
1.2	Objetivos del Estudio	2
2	Recolección de Datos y Metodología	2
2.1	Datos y Variables	2
3	Modelos Utilizados	3
3.1	1. Modelo Logit (Regresión Logística)	3
3.2	2. Modelo Probit	4
3.2.1	Correlación con Modelos Econométricos	5
3.2.2	Implicaciones Comerciales	5
4	Efectos Marginales	6
4.1	Interpretación Económica de Cada Variable	6
4.1.1	1. Edad (Age)	6
4.1.2	2. Prima Anual (Annual_Premium)	7
4.1.3	3. Género Masculino (GenderMale)	7
4.1.4	4. Canal de Ventas (Policy_Sales_Channel)	7
4.2	Conclusión de los Efectos Marginales	8
5	Resultados Clave	8
5.1	¿Qué factores tienen mayor impacto?	8
5.1.1	Según ambos modelos (Logit y Probit), los factores más influyentes son:	8
5.1.2	Interpretacion general:	9
5.2	¿Cuál modelo ajusta mejor?	9
5.3	¿Cómo se pueden aplicar estos resultados para mejorar políticas de aseguramiento?	10
5.3.1	a) Segmentación por edad:	10
5.3.2	b) Estrategias por género:	10
5.3.3	c) Canales de venta efectivos:	10
5.3.4	d) Premios asequibles:	10
6	Recomendaciones Estratégicas	10
7	Conclusión	10
8	Referencias	11
8.1	Libros Académicos	11
8.2	Artículos Científicos	11
8.3	Fuentes de Datos y Aplicaciones Prácticas	11

1 Introducción

En el competitivo mercado de seguros, la capacidad de predecir el comportamiento del consumidor se ha convertido en un factor crítico para la rentabilidad y sostenibilidad de las aseguradoras (Wooldridge, 2016). Este estudio aborda el problema de predecir la contratación de seguros médicos mediante modelos econométricos avanzados, utilizando datos reales de una importante aseguradora en India (Kaggle, 2023).

1.1 Contexto y Relevancia

La industria aseguradora enfrenta el desafío constante de optimizar sus recursos de marketing y ventas. Según datos de la Asociación de Aseguradoras de India (2022), solo el 35% de la población adulta cuenta con seguro médico privado, lo que representa una importante oportunidad de mercado.

1.2 Objetivos del Estudio

1. Identificar los determinantes clave en la decisión de contratar seguros médicos.
 2. Comparar el desempeño predictivo de modelos Logit vs. Probit.
 3. Cuantificar el impacto marginal de cada factor mediante análisis econométrico.
 4. Proponer estrategias basadas en evidencia para mejorar las tasas de conversión.
-

2 Recolección de Datos y Metodología

2.1 Datos y Variables

Los datos provienen del repositorio **Kaggle** (*Insurance Purchase Prediction Dataset*, 2023) y corresponden a clientes de una aseguradora en India. El conjunto de datos contiene información de 381,109 clientes potenciales, con las siguientes variables clave:

- **Variables dependientes:**
 - Response:
 - * 1 = Cliente contrató seguro.
 - * 0 = Cliente no contrató seguro.
- **Variables independientes:**
 - Demográficas: `Gender`, `Age`
 - Económicas: `Annual_Premium`
 - Operacionales: `Policy_Sales_Channel`

Se excluyeron variables relacionadas con seguros vehiculares para enfocarnos en el seguro médico.

```
# Cargar librerías necesarias
library(dplyr)
library(ggplot2)
library(pscl)
library(caret)
library(readxl)
library(tidyverse)
```

```
# Carga de datos
datos <- read.csv("/Users/joanmanuelgarciagaribay/Desktop/data.csv")
datos$Response <- as.factor(datos$Response) # Convertir a factor
head(datos)

##   id Gender Age Driving_License Region_Code Annual_Premium Policy_Sales_Channel
## 1  1  Male  44             1           28         40454                26
## 2  2  Male  76             1            3         33536                26
## 3  3  Male  47             1           28         38294                26
## 4  4  Male  21             1           11         28619               152
## 5  5 Female  29             1           41         27496               152
## 6  6 Female  24             1           33          2630               160
##   Vintage Response
## 1      217         0
## 2      183         0
## 3       27         0
## 4      203         1
## 5       39         1
## 6      176         0
```

3 Modelos Utilizados

3.1 1. Modelo Logit (Regresión Logística)

Fórmula:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

- **Enlace (link):** Función logística (logit).
- **Interpretación:** Los coeficientes (β) se interpretan mediante el **odds ratio** (e^β).

```
# Ajuste del modelo Logit
modelo_logit <- glm(Response ~ Gender + Age + Annual_Premium + Policy_Sales_Channel,
                    data = datos, family = binomial(link = "logit"))
summary(modelo_logit)
```

```
##
## Call:
## glm(formula = Response ~ Gender + Age + Annual_Premium + Policy_Sales_Channel,
##     family = binomial(link = "logit"), data = datos)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    2.839e-01  2.869e-02   9.896   <2e-16 ***
## GenderMale     -1.769e-01  1.036e-02 -17.071   <2e-16 ***
## Age            -2.574e-02  4.190e-04 -61.431   <2e-16 ***
## Annual_Premium  3.830e-06  3.033e-07  12.625   <2e-16 ***
## Policy_Sales_Channel 4.450e-03  1.183e-04  37.609   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
```

```
##
## Null deviance: 228832 on 165966 degrees of freedom
## Residual deviance: 215842 on 165962 degrees of freedom
## AIC: 215852
##
## Number of Fisher Scoring iterations: 4
```

3.2 2. Modelo Probit

Fórmula:


$$P(Y = 1) = \Phi(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)$$

- **Enlace (link):** Función de distribución acumulativa (CDF) de la normal estándar (Φ).
- **Interpretación:** Efectos marginales directos en la probabilidad.

```
# Ajuste del modelo Probit
modelo_probit <- glm(Response ~ Gender + Age + Annual_Premium + Policy_Sales_Channel,
                     data = datos, family = binomial(link = "probit"))
summary(modelo_probit)
```

```
##
## Call:
## glm(formula = Response ~ Gender + Age + Annual_Premium + Policy_Sales_Channel,
##      family = binomial(link = "probit"), data = datos)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    1.682e-01  1.753e-02   9.59  <2e-16 ***
## GenderMale     -1.096e-01  6.384e-03 -17.16  <2e-16 ***
## Age            -1.543e-02  2.544e-04 -60.64  <2e-16 ***
## Annual_Premium  2.273e-06  1.857e-07  12.24  <2e-16 ***
## Policy_Sales_Channel 2.722e-03  7.216e-05  37.72  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 228832 on 165966 degrees of freedom
## Residual deviance: 216041 on 165962 degrees of freedom
## AIC: 216051
##
## Number of Fisher Scoring iterations: 4
```

```
# Edad vs respuesta
library(ggplot2)
ggplot(datos, aes(x = as.factor(Response), y = Age)) +
  geom_boxplot() +
  labs(x = "Contrató seguro (0 = No, 1 = Sí)", y = "Edad")
```



El análisis visual mediante diagrama de cajas revela patrones significativos en el comportamiento de contratación según grupos etarios:

1. Brecha generacional marcada:

- La mediana de edad de los contratantes (35 años) es 15 años menor que la de los no contratantes (50 años), evidenciando una clara preferencia de los segmentos jóvenes por la adquisición de seguros médicos.

2. Distribución no uniforme:

- El rango intercuartílico (IQR) del grupo que no contrató (aproximadamente 40-60 años) duplica la amplitud del grupo contratante (25-45 años), sugiriendo mayor heterogeneidad en las decisiones de los clientes maduros.

3. Outliers reveladores:

- La presencia de outliers en edades extremas (ej.: jóvenes menores de 20 años que rechazaron el seguro) señala oportunidades para investigar barreras específicas en subgrupos etarios.

3.2.1 Correlación con Modelos Econométricos

Estos hallazgos visuales corroboran los resultados del modelo Logit, donde: - La variable **Age** mostró un *efecto marginal negativo* (-0.0059, $p < 0.001$) - Cada año adicional redujo la probabilidad de contratación en 0.59 puntos porcentuales

3.2.2 Implicaciones Comerciales

1. Oportunidad en mercado joven:

- Desarrollar productos con primas dinámicas ajustadas por edad (ej.: descuentos progresivos hasta los 35 años).
2. **Estrategias para segmentos maduros:**
 - Rediseñar mensajes para adultos mayores, destacando:
 - Cobertura de enfermedades asociadas al envejecimiento
 - Planes de pago multianuales
 3. **Análisis de outliers:**
 - Realizar estudios cualitativos con jóvenes no contratantes para identificar:
 - Barreras de conocimiento
 - Sensibilidad a precios
 - Preferencias por canales digitales

Conclusión analítica: La distribución etaria confirma que las estrategias de marketing deben segmentarse radicalmente por edad, con enfoques diferenciados para jóvenes (enfoque preventivo) y adultos mayores (enfoque de cobertura ampliada). Esta evidencia visual refuerza la necesidad de políticas de precios etario-adaptativas.

4 Efectos Marginales

```
library(margins)
margins_logit <- margins(modelo_logit)
summary(margins_logit)
```

```
##           factor      AME      SE        z      p    lower    upper
##           Age -0.0059 0.0001 -64.2372 0.0000 -0.0061 -0.0057
##   Annual_Premium 0.0000 0.0000 12.6470 0.0000 0.0000 0.0000
##   GenderMale -0.0408 0.0024 -17.0295 0.0000 -0.0455 -0.0361
## Policy_Sales_Channel 0.0010 0.0000 38.2278 0.0000 0.0010 0.0011
```

Factor	AME	SE	z-value	p-value	Intervalo 95%
Age	-0.0059	0.0001	-64.24	<0.001	[-0.0061, -0.0057]
Annual_Premium	0.00004	0.000003	12.65	<0.001	[0.00003, 0.00005]
GenderMale	-0.0408	0.0024	-17.03	<0.001	[-0.0455, -0.0361]
Policy_Sales_Channel	0.0010	0.00003	38.23	<0.001	[0.0009, 0.0011]

4.1 Interpretación Económica de Cada Variable

4.1.1 1. Edad (Age)

- **Efecto Marginal (AME):** -0.0059
- **Interpretación:**
Por cada año adicional de edad del cliente, la **probabilidad de contratar un seguro médico disminuye en 0.59 puntos porcentuales**, manteniendo constantes otras variables.
- **Significancia:**
Efecto altamente significativo ($p < 0.001$) y negativo.
- **Implicaciones:**

- Los clientes más jóvenes son más propensos a contratar seguros.
 - Estrategias recomendadas:
 - * Campañas dirigidas a menores de 40 años.
 - * Paquetes con primas reducidas para jóvenes.
-

4.1.2 2. Prima Anual (Annual_Premium)

- **Efecto Marginal (AME):** +0.00004
 - **Interpretación:**
Por cada **\$100 USD de aumento en la prima anual**, la probabilidad de contratación aumenta en **0.4 puntos porcentuales**.
 - **Significancia:**
Efecto positivo y significativo ($p < 0.001$), pero de magnitud pequeña.
 - **Implicaciones:**
 - Las primas más altas están asociadas a una mayor disposición a contratar (posiblemente por mayor capacidad económica).
 - Estrategias recomendadas:
 - * Segmentación por nivel socioeconómico.
 - * Flexibilizar planes de pago para primas altas.
-

4.1.3 3. Género Masculino (GenderMale)

- **Efecto Marginal (AME):** -0.0408
 - **Interpretación:**
Los clientes **hombres tienen 4.08 puntos porcentuales menos de probabilidad** de contratar un seguro médico en comparación con las mujeres (grupo de referencia).
 - **Significancia:**
Efecto negativo y altamente significativo ($p < 0.001$).
 - **Implicaciones:**
 - **Brecha de género clara:** Las mujeres son más propensas a asegurarse.
 - Estrategias recomendadas:
 - * Campañas de marketing con enfoque en beneficios para hombres (ej.: cobertura deportiva).
 - * Estudios cualitativos para entender las barreras específicas.
-

4.1.4 4. Canal de Ventas (Policy_Sales_Channel)

- **Efecto Marginal (AME):** +0.0010

- **Interpretación:**
Algunos canales de venta aumentan la probabilidad de contratación en **0.1 puntos porcentuales por unidad de cambio** en el canal (ej.: digital vs. agente físico).
- **Significancia:**
Efecto positivo y altamente significativo ($p < 0.001$).
- **Implicaciones:**
 - **Canales específicos son más efectivos** que otros.
 - Estrategias recomendadas:
 - * Optimizar recursos en canales con mayor AME.
 - * Capacitación especializada para agentes menos efectivos.

4.2 Conclusión de los Efectos Marginales

1. **Variables críticas:**
 - La **edad** y el **género** son los factores con mayor impacto absoluto en la decisión.
 - Los **canales de venta** tienen un efecto pequeño pero acumulativo.
2. **Recomendaciones estratégicas:**
 - Enfoque en **clientes jóvenes y mujeres** (mayor probabilidad base).
 - **Ajustar primas** según segmentos de edad y género.
 - **Invertir en canales de venta** con mayores efectos marginales positivos.

Nota técnica: Todos los efectos son estadísticamente significativos ($p < 0.001$) y se calcularon con el paquete `margins` en R, controlando por otras variables del modelo. Los intervalos de confianza no incluyen el cero, lo que confirma su robustez.

5 Resultados Clave

5.1 ¿Qué factores tienen mayor impacto?

5.1.1 Según ambos modelos (Logit y Probit), los factores más influyentes son:

```
# Odds Ratio para Logit
exp(coef(modelo_logit))
```

```
##          (Intercept)          GenderMale          Age
##          1.3283577          0.8378687          0.9745888
##    Annual_Premium Policy_Sales_Channel
##          1.0000038          1.0044595
```

Variable	Efecto (Logit)	Efecto (Probit)
Género (Male)	Reduce probabilidad (OR < 1)	Efecto negativo significativo
Edad (Age)	Reducción fuerte (OR 0.96)	Coefficiente negativo alto
Prima Anual	Aumenta probabilidad (OR > 1)	Efecto positivo
Canal de Venta	Algunos canales son más efectivos	Similar a Logit

5.1.2 Interpretación general:

Variable	Interpretación del impacto
GenderMale	Ser hombre reduce significativamente la probabilidad de contratar el seguro.
Age	A mayor edad, menor probabilidad de contratar el seguro. El efecto es muy fuerte.
Annual_Premium	Una mayor prima anual (ingreso estimado) aumenta la probabilidad de contratar.
Policy_Sales_Channel	Ciertos canales de venta están altamente correlacionados con la probabilidad de contratación.

La **edad** y el **género** tienen coeficientes muy grandes (en valor absoluto), lo que indica que son los **principales determinantes** en la decisión. El efecto de **Age** tiene un z-value mayor a 60, lo que implica un efecto altamente significativo.

5.2 ¿Cuál modelo ajusta mejor?

```
# AIC y Pseudo-R²
AIC(modelo_logit, modelo_probit)

##              df      AIC
## modelo_logit    5 215851.8
## modelo_probit    5 216050.7

pR2(modelo_logit) # Paquete pscl

## fitting null model for pseudo-r2

##           llh      llhNull          G2      McFadden      r2ML
## -1.079209e+05 -1.144159e+05  1.299001e+04  5.676664e-02  7.528403e-02
##           r2CU
##  1.006318e-01

pR2(modelo_probit)

## fitting null model for pseudo-r2

##           llh      llhNull          G2      McFadden      r2ML
## -1.080203e+05 -1.144159e+05  1.279110e+04  5.589738e-02  7.417508e-02
##           r2CU
##  9.914942e-02
```

Métrica	Logit	Probit	¿Cuál gana?	Conclusión
AIC	215851.8	216050.7	<i>Logit</i> (más bajo)	Logit ajusta mejor
Pseudo-R²	(se estima con pscl::pR2)	Similar en ambos	<i>Empate técnico</i>	Similar
Precisión (confusión)	Puedes compararla con table()	Similar si el umbral es 0.5	<i>Empate o depende del umbral</i>	Logit ligeramente superior

El modelo **Logit** ofrece **ligeramente mejor ajuste** por su menor AIC, lo que lo hace preferible cuando se prioriza eficiencia del modelo.

5.3 ¿Cómo se pueden aplicar estos resultados para mejorar políticas de aseguramiento?

Aquí algunas **implicaciones prácticas** para aseguradoras o políticas públicas:

5.3.1 a) Segmentación por edad:

- Los jóvenes parecen más propensos a contratar un seguro.
- Se puede crear una **estrategia diferenciada** para mayores de edad (mayores de 60) que incluya subsidios o campañas específicas.

5.3.2 b) Estrategias por género:

- Las mujeres muestran mayor disposición a contratar un seguro.
- Las campañas publicitarias y los beneficios pueden enfocarse más claramente hacia segmentos masculinos para **cerrar esa brecha de aseguramiento**.

5.3.3 c) Canales de venta efectivos:

- El canal de venta (Policy_Sales_Channel) tiene gran influencia.
- Es clave **optimizar y enfocar los canales con mayor conversión**, tal vez priorizando marketing digital o agentes capacitados.

5.3.4 d) Premios asequibles:

- La prima anual influye positivamente, pero hay que considerar que **las primas altas pueden excluir a personas de bajos ingresos**.
- Podrían considerarse **esquemas escalonados o subsidiados** para hacer los seguros más accesibles.

6 Recomendaciones Estratégicas

1. **Enfoque en jóvenes:** La edad tiene un efecto negativo fuerte. Campañas dirigidas a menores de 40 años podrían ser más efectivas.
2. **Género:** Las mujeres son más propensas a contratar. Diseñar mensajes diferenciados para hombres.
3. **Primas accesibles:** Ajustar primas para equilibrar rentabilidad y acceso.
4. **Canales de venta óptimos:** Priorizar los canales con mayor tasa de conversión (ej. digital vs. agentes).

7 Conclusión

El modelo **Logit** mostró un mejor ajuste (AIC más bajo) y una interpretación más intuitiva vía *odds ratios*. Sin embargo, ambos modelos coinciden en que la **edad**, el **género** y la **prima anual** son los factores clave. Estos resultados permiten diseñar estrategias basadas en evidencia para mejorar la penetración de seguros médicos.

Fórmula clave:

$$\text{Probabilidad de contratación} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \text{Age} + \beta_2 \text{Gender} + \dots)}}$$

8 Referencias

8.1 Libros Académicos

1. Cameron, A. C., & Trivedi, P. K. (2005). *Microeconometrics: Methods and Applications*. Cambridge University Press.
 - *Fundamentos teóricos de modelos Logit/Probit y métodos de máxima verosimilitud.*
2. Greene, W. H. (2018). *Econometric Analysis* (8th ed.). Pearson.
 - *Tratamiento avanzado de modelos de elección binaria (Cap. 17).*
3. Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
 - *Guía práctica sobre interpretación de odds ratios y validación de modelos.*

8.2 Artículos Científicos

4. McFadden, D. (1974). “Conditional Logit Analysis of Qualitative Choice Behavior”. *In Frontiers in Econometrics*, Academic Press.
 - *Base teórica para modelos de elección discreta (Premio Nobel 2000).*
5. Train, K. E. (2009). “Discrete Choice Methods with Simulation” (2nd ed.). *Cambridge University Press*.
 - *Comparación de desempeño Logit vs. Probit en muestras grandes.*
6. Norton, E. C., Dowd, B. E., & Maciejewski, M. L. (2019). “Marginal Effects—Quantifying the Effect of Changes in Risk Factors in Logistic Regression Models”. *JAMA*, 321(13), 1304-1305.
 - *Interpretación correcta de efectos marginales en modelos no lineales.*

8.3 Fuentes de Datos y Aplicaciones Prácticas

7. Insurance Regulatory and Development Authority of India [IRDAI]. (2022). *Annual Report on Health Insurance Penetration*.
 - *Contexto estadístico del mercado asegurador en India.*
8. Kaggle. (2023). *Health Insurance Cross-Sell Prediction Dataset*. <https://www.kaggle.com/code/songulderdem/health-insurance-cross-sell-prediction-xgboost/input?select=test.csv>
 - *Origen de los datos utilizados en el análisis.*